

«Национальный исследовательский университет ИТМО»

РАСЧЁТНО-ГРАФИЧЕСКАЯ РАБОТА №3

по дисциплине

«Математическая статистика»

Регрессионные модели и их интерпретация

Выполнил: Голинский Данила Владимирович

Группа: К3240

Вариант: А-4

Проверил: Тузиков Фёдор Николаевич

Санкт-Петербург

2026

Содержание

1	Описание задачи и источника данных	3
1.1	Идентификатор варианта	3
1.2	Источник данных	3
1.3	Прогнозное значение	3
2	Первичный анализ данных	4
2.1	Фрагмент таблицы исходных данных	4
2.2	Описательная статистика	4
2.3	Диаграмма рассеяния и гипотеза о характере связи	5
3	Построение регрессионных моделей	5
3.1	Модель 1: Линейная регрессия	5
3.1.1	Оценки параметров (МНК)	5
3.1.2	Итоговое уравнение	6
3.2	Модель 2: Квадратичная регрессия	6
3.2.1	Оценки параметров	6
3.2.2	Итоговое уравнение	6
3.3	Модель 3: Степенная регрессия $y = a \cdot x^b$	6
3.3.1	Линеаризация	6
3.3.2	Итоговое уравнение	7
4	Сравнение моделей	7
4.1	Критерии качества	7
4.2	Анализ результатов	8
5	Подробный статистический анализ линейной модели	8
5.1	Остатки	8
5.2	Остаточная сумма квадратов и оценка дисперсии	9
5.3	Стандартные ошибки коэффициентов	9
5.4	Доверительные интервалы (уровень 95%)	10
5.5	Проверка значимости коэффициента наклона	10

6	Прогноз при $x^* = 21,0240$	11
6.1	Прогнозные значения по трём моделям	11
6.2	Выбор основной модели для прогноза	11
6.3	Интерпретация прогноза	11
7	Итоговый вывод	12
	Приложение. Используемые инструменты и функции	12
	Приложение. Python-код анализа	13

Описание задачи и источника данных

Идентификатор варианта

Вариант **А-4**. Группа А: направления «Технологии защиты информации», «Системное и прикладное программное обеспечение», «Компьютерные системы и технологии», «Мобильные и сетевые технологии» и др.

Источник данных

Данные получены из набора *CPU Performance Data Set* (машинная производительность процессоров), хорошо известного в задачах регрессионного анализа. Исходный набор содержит характеристики различных процессоров: число процессоров, объём кэша, тактовую частоту, максимальный объём каналов памяти и оценку относительной производительности (benchmarked relative performance, PRP). Набор содержит 209 исходных строк.

Срез для варианта А-4: из исходного набора выбраны $n = 60$ наблюдений. Переменные:

- x — *максимальный объём каналов памяти (MMAX)*, условных единиц, характеризует максимальный объём оперативной памяти, с которым может работать процессор;
- y — *относительная производительность (PRP)*, условных единиц, вычисляется как публикуемая относительная производительность по сравнению с эталонной машиной.

Содержательный смысл задачи: требуется выяснить, в какой степени максимальный объём каналов памяти определяет производительность вычислительной системы, и построить регрессионную модель, пригодную для прогноза.

Прогнозное значение

По условию карточки варианта $x^* = 21,0240$ — это 108% от среднего уровня фактора $\bar{x} = 19,4667$:

$$x^* = 1,08 \cdot \bar{x} = 1,08 \cdot 19,4667 \approx 21,024.$$

Первичный анализ данных

Фрагмент таблицы исходных данных

В таблице 1 приведены первые 15 из 60 наблюдений.

Таблица 1: Фрагмент исходных данных (наблюдения 1–15 из 60)

i	x_i	y_i	i	x_i	y_i
1	1	24	9	3	50
2	1	20	10	4	16
3	1	16	11	4	20
4	2	60	12	4	12
5	2	26	13	5	40
6	2	18	14	5	36
7	3	69	15	5	40
8	3	14	... (всего 60 наблюдений)		

Среди всех 60 наблюдений наиболее заметны несколько «выбросов» с очень высокой производительностью (например, $y_{58} = 1144$ при $x_{58} = 64$ и $y_{60} = 915$ при $x_{60} = 176$), которые существенно влияют на форму зависимости.

Описательная статистика

Ключевые сводные характеристики переменных:

$$\begin{aligned}\bar{x} &= \frac{1}{n} \sum_{i=1}^n x_i = 19,4667, & \bar{y} &= \frac{1}{n} \sum_{i=1}^n y_i = 124,2667, \\ S_{xx} &= \sum_{i=1}^n (x_i - \bar{x})^2 = 49\,776,93, \\ S_{xy} &= \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) = 224\,782,53, \\ S_{yy} &= \text{TSS} = \sum_{i=1}^n (y_i - \bar{y})^2 = 2\,388\,034,93.\end{aligned}$$

Диаграмма рассеяния и гипотеза о характере связи




Рис. 1: Основные графики анализа (фрагмент левый верхний — диаграмма рассеяния)

На диаграмме рассеяния (рис. 1, панель 1) прослеживается **положительная нелинейная зависимость**: с ростом максимального объёма каналов памяти x производительность y в целом растёт, однако разброс значений y при одном и том же x очень велик, что свидетельствует о наличии и других факторов, влияющих на производительность.

Гипотеза: связь между x и y *положительная*, скорее всего *нелинейная* (возможна степенная или квадратичная форма), так как при малых x значения y концентрируются в нижней части оси, а при больших x появляются экстремально высокие наблюдения.

Построение регрессионных моделей

Модель 1: Линейная регрессия

3.1.1 Оценки параметров (МНК)

Для линейной модели $y = \theta_0 + \theta_1 x$ оценки методом наименьших квадратов (МНК) вычисляются по формулам:

$$\hat{\theta}_1 = \frac{S_{xy}}{S_{xx}} = \frac{224\,782,53}{49\,776,93} = 4,5158,$$

$$\hat{\theta}_0 = \bar{y} - \hat{\theta}_1 \bar{x} = 124,2667 - 4,5158 \cdot 19,4667 = 36,3591.$$

3.1.2 Итоговое уравнение

$$\boxed{\hat{y} = 36,3591 + 4,5158 \cdot x} \quad (1)$$

Интерпретация: при увеличении максимального объёма каналов памяти на 1 условную единицу относительная производительность в среднем увеличивается на 4,5158 усл. ед. Свободный член 36,36 усл. ед. указывает на «базовый» уровень производительности при $x \rightarrow 0$, хотя это значение не имеет прямого физического смысла (реальные $x \geq 1$).

Модель 2: Квадратичная регрессия

3.2.1 Оценки параметров

Квадратичная модель $y = c_0 + c_1x + c_2x^2$ оценивается методом МНК в матричной форме (библиотека `numpy.polyfit` решает систему нормальных уравнений). Полученные коэффициенты:

$$c_2 = -0,013089, \quad c_1 = 6,4043, \quad c_0 = 15,4162.$$

3.2.2 Итоговое уравнение

$$\boxed{\hat{y} = 15,4162 + 6,4043 \cdot x - 0,0131 \cdot x^2} \quad (2)$$

Интерпретация: отрицательный коэффициент при x^2 формально означает «замедление» роста производительности с увеличением x . Вершина параболы находится при $x_{\max} = -c_1/(2c_2) \approx 244$, что выходит за пределы наблюдаемого диапазона данных ($x \leq 176$), поэтому в данном диапазоне квадратичная кривая остаётся монотонно возрастающей.

Модель 3: Степенная регрессия $y = a \cdot x^b$

3.3.1 Линеаризация

Степенная модель $y = a \cdot x^b$ приводится к линейному виду логарифмированием:

$$\ln y = \ln a + b \cdot \ln x.$$

Обозначим $Y' = \ln y$, $X' = \ln x$, $A = \ln a$. Тогда задача сводится к линейной регрессии $Y' = A + b \cdot X'$, оцениваемой МНК:

$$\overline{\ln x} = \frac{1}{n} \sum_{i=1}^n \ln x_i = 1,9890,$$

$$\overline{\ln y} = \frac{1}{n} \sum_{i=1}^n \ln y_i = 3,9402,$$

$$S'_{xx} = \sum_{i=1}^n (\ln x_i - \overline{\ln x})^2 = 109,7065,$$

$$S'_{xy} = \sum_{i=1}^n (\ln x_i - \overline{\ln x})(\ln y_i - \overline{\ln y}) = 74,5028.$$

$$b = \frac{S'_{xy}}{S'_{xx}} = \frac{74,5028}{109,7065} = 0,6788, \quad A = \overline{\ln y} - b \cdot \overline{\ln x} = 3,9402 - 0,6788 \cdot 1,9890 = 2,5463,$$

$$a = e^A = e^{2,5463} = 12,7602.$$

3.3.2 Итоговое уравнение

$$\boxed{\hat{y} = 12,7602 \cdot x^{0,6788}} \quad (3)$$

Интерпретация: показатель степени $b = 0,679 < 1$ означает *убывающую отдачу* — производительность растёт медленнее, чем линейно. При удвоении x производительность увеличивается примерно в $2^{0,679} \approx 1,60$ раза.

Сравнение моделей

Критерии качества

Для трёх моделей вычислены: коэффициент детерминации R^2 , среднеквадратическая ошибка RMSE и средняя ошибка аппроксимации A :

$$R^2 = 1 - \frac{\text{RSS}}{\text{TSS}}, \quad \text{RMSE} = \sqrt{\frac{\text{RSS}}{n}}, \quad A = \frac{100\%}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right|. \quad (4)$$

Таблица 2: Сравнение трёх регрессионных моделей

Модель	Уравнение	R^2	RMSE	A , %
Линейная	$\hat{y} = 36,36 + 4,52x$	0,4249	151,31	123,64
Квадратичная	$\hat{y} = 15,42 + 6,40x - 0,013x^2$	0,4362	149,82	109,88
Степенная	$\hat{y} = 12,76 \cdot x^{0,6788}$	0,3141	165,25	76,53

Анализ результатов

1. **По R^2 :** Наилучшее объяснение дисперсии y даёт квадратичная модель ($R^2 = 0,436$), линейная модель незначительно уступает ($R^2 = 0,425$). Степенная модель в исходном пространстве демонстрирует $R^2 = 0,314$, однако в логарифмическом пространстве её $R^2_{\log} = 0,492$, что свидетельствует о хорошем описании *структуры* данных после линеаризации. Общая невысокая величина R^2 объясняется большим разбросом данных.
2. **По RMSE:** Квадратичная модель снова минимальна (RMSE = 149,82), линейная — 151,31. Степенная уступает по этому критерию (165,25).
3. **По средней ошибке аппроксимации A :** Здесь картина принципиально иная. Степенная модель достигает $A = 76,53\%$ — значительно лучше, чем квадратичная (109,88%) и линейная (123,64%). Это объясняется тем, что степенная модель адекватнее описывает малые значения y (при малых x): линейная и квадратичная сильно завышают прогноз в этой области, давая большую относительную ошибку.
4. **По графикам остатков:** Во всех трёх моделях остатки не случайны — наблюдается гетероскедастичность (дисперсия остатков растёт с увеличением x). Это предсказуемо для данных с широким диапазоном x (от 1 до 176). Степенная модель в логарифмической шкале показывает более равномерный разброс остатков.

Вывод: ни одна модель не является «идеальной» для данных с высокой гетероскедастичностью. По совокупности критериев в исходном пространстве квадратичная модель незначительно лучше. Степенная модель предпочтительна с точки зрения относительной ошибки и содержательного смысла (закон «убывающей отдачи»). Для целей прогноза основной будет выбрана **квадратичная модель** как имеющая наилучший R^2 и RMSE в исходном пространстве.

Подробный статистический анализ линейной модели

Остатки

Остаток i -го наблюдения: $e_i = y_i - \hat{y}_i$. Фрагмент таблицы остатков приведён в таблице 3.

Таблица 3: Фрагмент таблицы остатков линейной модели (наблюдения 1–15)

i	x_i	y_i	$\hat{y}_i$	e_i
1	1	24	40,88	−16,88
2	1	20	40,88	−20,88
3	1	16	40,88	−24,88
4	2	60	45,39	14,61
5	2	26	45,39	−19,39
6	2	18	45,39	−27,39
7	3	69	49,91	19,09
8	3	14	49,91	−35,91
9	3	50	49,91	0,09
10	4	16	54,42	−38,42
11	4	20	54,42	−34,42
12	4	12	54,42	−42,42
13	5	40	58,94	−18,94
14	5	36	58,94	−22,94
15	5	40	58,94	−18,94

Остаточная сумма квадратов и оценка дисперсии

Остаточная сумма квадратов:

$$\text{RSS} = \sum_{i=1}^n e_i^2 = 1\,373\,641,41.$$

Несмещённая оценка дисперсии ошибки (с $n - 2 = 58$ степенями свободы):

$$s^2 = \frac{\text{RSS}}{n - 2} = \frac{1\,373\,641,41}{58} = 23\,683,47, \quad s = \sqrt{s^2} = 153,89.$$

Стандартные ошибки коэффициентов

Стандартная ошибка наклона:

$$\text{SE}(\hat{\theta}_1) = \frac{s}{\sqrt{S_{xx}}} = \frac{153,89}{\sqrt{49\,776,93}} = \frac{153,89}{223,10} = 0,6898.$$

Стандартная ошибка свободного члена:

$$\text{SE}(\hat{\theta}_0) = s \sqrt{\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}}} = 153,89 \cdot \sqrt{\frac{1}{60} + \frac{(19,4667)^2}{49\,776,93}} = 153,89 \cdot 0,1559 = 23,98.$$

Доверительные интервалы (уровень 95%)

Квантиль распределения Стьюдента при $\alpha = 0,05$ и $\nu = 58$:

$$t_{0,975;58} = 2,0017.$$

95% доверительные интервалы для коэффициентов:

$$\hat{\theta}_0 \pm t \cdot \text{SE}(\hat{\theta}_0) = 36,36 \pm 2,0017 \cdot 23,98 = 36,36 \pm 47,99 :$$

$$\theta_0 \in (-11,64; 84,36).$$

$$\hat{\theta}_1 \pm t \cdot \text{SE}(\hat{\theta}_1) = 4,5158 \pm 2,0017 \cdot 0,6898 = 4,5158 \pm 1,3807 :$$

$$\theta_1 \in (3,135; 5,897).$$

Важное замечание: доверительный интервал для θ_0 содержит нуль, что означает статистическую незначимость свободного члена на уровне 5%. Это не является проблемой с практической точки зрения. Интервал для θ_1 нуль *не* содержит — линейная зависимость статистически значима.

Проверка значимости коэффициента наклона

Тестируются гипотезы:

$$H_0 : \theta_1 = 0 \quad (\text{нет линейной связи}), \quad H_1 : \theta_1 \neq 0.$$

Наблюдаемая статистика Стьюдента:

$$t_{\text{набл}} = \frac{\hat{\theta}_1}{\text{SE}(\hat{\theta}_1)} = \frac{4,5158}{0,6898} = 6,547.$$

Критическое значение: $t_{\text{крит}} = 2,0017$.

Поскольку $|t_{\text{набл}}| = 6,547 > 2,0017 = t_{\text{крит}}$, гипотеза H_0 **отвергается** на уровне значимости $\alpha = 0,05$.

Вывод: коэффициент наклона θ_1 статистически значимо отличается от нуля. Линейная связь между x (максимальный объём каналов) и y (производительность) является статистически значимой.

Прогноз при $x^* = 21,0240$

Прогнозные значения по трём моделям

Для заданного $x^* = 21,0240$ (108% от $\bar{x} = 19,4667$) прогнозы по трём моделям:

Таблица 4: Прогнозные значения производительности при $x^* = 21,0240$

Модель	Формула расчёта	$\hat{y}(x^*)$
Линейная	$36,36 + 4,5158 \cdot 21,024$	131,30
Квадратичная	$15,42 + 6,4043 \cdot 21,024 - 0,0131 \cdot 21,024^2$	144,27
Степенная	$12,7602 \cdot 21,024^{0,6788}$	100,86

Выбор основной модели для прогноза

В качестве основной модели для прогноза выбирается **квадратичная** модель по следующим соображениям:

- Наилучший $R^2 = 0,436$ в исходном пространстве.
- Наименьший $\text{RMSE} = 149,82$.
- Прогнозная точка $x^* = 21,024$ лежит вблизи центра диапазона наблюдаемых значений x (среднее $\bar{x} = 19,47$), поэтому интерполяция надёжна.
- Квадратичная форма лучше улавливает нелинейный характер зависимости в центральной части диапазона.

Интерпретация прогноза

При максимальном объёме каналов памяти $x^* = 21,0240$ условных единиц (что соответствует 108% от среднего уровня по выборке) ожидаемая относительная производительность вычислительной системы по квадратичной модели составит около **144 усл. ед.**, что примерно на 16% выше, чем прогноз линейной модели (131 усл. ед.) и на 43% выше прогноза степенной модели (101 усл. ед.).

Содержательно: небольшое увеличение ресурсов памяти (с «среднего» до 108% от среднего) ожидаемо даёт умеренный прирост производительности. Однако следует помнить, что все три модели дают довольно «широкий» прогноз из-за высокой остаточной изменчивости данных ($s \approx 154$ усл. ед.): реальное значение может сильно отличаться от точечного прогноза.

Итоговый вывод

В данной расчётно-графической работе исследовалась зависимость *относительной производительности* вычислительной системы (y , усл. ед.) от *максимального объёма каналов памяти* (x , усл. ед.) на основе 60 наблюдений из набора данных CPU Performance Data Set.

Были построены три регрессионные модели: линейная ($\hat{y} = 36,36 + 4,52x$), квадратичная ($\hat{y} = 15,42 + 6,40x - 0,013x^2$) и степенная ($\hat{y} = 12,76 \cdot x^{0,679}$). Все модели подтверждают *положительную* связь между переменными: с ростом максимального объёма каналов производительность в среднем увеличивается.

По совокупности критериев (R^2 , RMSE) предпочтительной оказалась **квадратичная** модель ($R^2 = 0,436$, RMSE = 149,82). Степенная модель, несмотря на несколько меньший R^2 в исходном пространстве, показала наилучшую среднюю относительную ошибку аппроксимации ($A = 76,53\%$) и содержательно обоснована принципом «убывающей отдачи» от ресурсов памяти (показатель степени $b = 0,679 < 1$).

Статистический анализ линейной модели подтвердил **значимость** коэффициента наклона ($t_{\text{набл}} = 6,547 \gg t_{\text{крит}} = 2,002$), то есть связь между x и y не является случайной. Доверительный интервал для θ_1 равен (3,135; 5,897) и не содержит нуль.

Прогноз при $x^* = 21,024$ по квадратичной модели: $\hat{y} \approx 144$ усл. ед. Относительно высокая остаточная дисперсия ($s \approx 154$ усл. ед.) указывает на присутствие других существенных факторов производительности, не включённых в однофакторную модель (например, тактовая частота, объём кэша), что является естественным ограничением данного исследования.

Приложение. Используемые инструменты и функции

Работа выполнена на языке **Python 3**. Используемые библиотеки:

- `numpy`: массивы, `np.sum`, `np.sqrt`, `np.polyfit`, `np.polyval`, `np.log`, `np.exp` — арифметические операции и МНК;
- `scipy.stats`: `stats.t.ppf(0.975, df=n-2)` — квантиль распределения Стьюдента;
- `matplotlib.pyplot`: построение диаграмм рассеяния, графиков моделей, остатков.

Все расчёты воспроизводимы при запуске файла `rgr3_a4_analysis.py`, прилагаемого к отчёту.

Приложение. Python-код анализа

Полный исходный код проекта доступен на GitHub:

https://github.com/Solitudek/Mat_Stat_RGR3

```
1 import numpy as np
2 import pandas as pd
3 import matplotlib.pyplot as plt
4 from scipy import stats
5 import warnings
6
7 warnings.filterwarnings('ignore')
8
9 df = pd.read_csv('RGR3_A_4.csv')
10
11 if 'x' not in df.columns or 'y' not in df.columns:
12     raise ValueError("CSV-
13                        'x'      'y'")
14
15 x = df['x'].to_numpy(dtype=float)
16 y = df['y'].to_numpy(dtype=float)
17
18 n = len(x)
19 x_star = 21.0240
20
21 print("=" * 70)
22 print("                                ")
23 print(df.head())
24
25
26 x_mean = np.mean(x)
27 y_mean = np.mean(y)
28
29 Sxx = np.sum((x - x_mean) ** 2)
30 Sxy = np.sum((x - x_mean) * (y - y_mean))
31 Syy = np.sum((y - y_mean) ** 2)
32
33 print("\n" + "=" * 70)
34 print("                                ")
```

```
35 print("=" * 70)
36
37 print(f"n = {n}")
38 print(f"x_mean = {x_mean:.4f}")
39 print(f"y_mean = {y_mean:.4f}")
40 print(f"Sxx = {Sxx:.4f}")
41 print(f"Sxy = {Sxy:.4f}")
42 print(f"Syy = {Syy:.4f}")
43
44
45 b1 = Sxy / Sxx
46 b0 = y_mean - b1 * x_mean
47
48 y_hat_lin = b0 + b1 * x
49 e_lin = y - y_hat_lin
50
51 RSS_lin = np.sum(e_lin ** 2)
52 R2_lin = 1 - RSS_lin / Syy
53 RMSE_lin = np.sqrt(RSS_lin / n)
54
55 print("\n" + "=" * 70)
56 print("                                ")
57 print("=" * 70)
58
59 print(f"y_hat = {b0:.4f} + {b1:.4f} * x")
60 print(f"R2 = {R2_lin:.4f}")
61 print(f"RMSE = {RMSE_lin:.4f}")
62
63
64 coeffs_q = np.polyfit(x, y, 2)
65
66 c2_q, c1_q, c0_q = coeffs_q
67
68 y_hat_quad = np.polyval(coeffs_q, x)
69
70 RSS_quad = np.sum((y - y_hat_quad) ** 2)
71 R2_quad = 1 - RSS_quad / Syy
72
73 print("\n" + "=" * 70)
74 print("                                ")
75 print("=" * 70)
```

```
76
77 print(f"y_hat = {c0_q:.4f} + {c1_q:.4f}*x + ({c2_q:.6f})*x^2")
78 print(f"R2 = {R2_quad:.4f}")
79
80
81 x_plot = np.linspace(x.min(), x.max(), 600)
82
83 y_plot_lin = b0 + b1 * x_plot
84 y_plot_quad = np.polyval(coeffs_q, x_plot)
85
86 fig, axes = plt.subplots(1, 2, figsize=(12, 5))
87
88 axes[0].scatter(x, y)
89 axes[0].plot(x_plot, y_plot_lin)
90
91 axes[1].scatter(x, y)
92 axes[1].plot(x_plot, y_plot_quad)
93
94 plt.tight_layout()
95
96 plt.savefig(
97     'rgr3_a4_plots.png',
98     dpi=300,
99     bbox_inches='tight'
100 )
```